

UNIDAD 1: INTRODUCCIÓN A LA IA

Índice

1. Inteligencia artificial (y qué no es IA)	2
Definición de IA	2
Un breve paseo por la historia	2
Tipos de inteligencia artificial	3
A. Según su alcance o capacidad.....	3
B. Según su enfoque (Los pilares actuales que se explican más adelante)	4
2. Machine learning y Deep Learning (dentro de la IA)	5
3. Redes neuronales	6
4. Modelos de aprendizaje	8
1. Aprendizaje Supervisado (<i>Supervised Learning</i>).....	8
2. Aprendizaje No Supervisado (<i>Unsupervised Learning</i>)	9
3. Aprendizaje Semi-Supervisado (<i>Semi-Supervised Learning</i>)	10
4. Aprendizaje por Refuerzo (<i>Reinforcement Learning</i>).....	10
5. Dataset	11
6. Data Science	13
7. Transformers (“la T del ChatGPT”)	15

Diseñadores

DALL-E



HE ROBADO TUS
IMÁGENES Y
LO USO PARA
GENERAR ARTE.



¡ESO ES ILEGAL!

Programadores

CHATGPT



HE ESCANEADO
TU CUENTA DE
GITHUB Y HE
ROBADO TU CÓDIGO



YO TAMBIÉN
LO ROBÉ

1. Inteligencia artificial (y qué no es IA)

Olvida las películas de ciencia ficción donde las máquinas cobran conciencia. Para un programador, la **Inteligencia Artificial (IA)** es un campo de la informática que busca crear sistemas capaces de realizar tareas que, tradicionalmente, requerían inteligencia humana. Esto incluye el razonamiento, el aprendizaje, la toma de decisiones y la comprensión del lenguaje natural.

Definición de IA

La **Inteligencia Artificial** es la rama de la informática que busca crear sistemas informáticos capaces de realizar tareas que, históricamente, requerían de la inteligencia humana. Estas tareas incluyen la capacidad de aprender de la experiencia (entrenamiento), identificar patrones en grandes volúmenes de datos, razonar para resolver problemas complejos, comprender el lenguaje natural y tomar decisiones de forma autónoma.

A diferencia del software tradicional basando en reglas explícitas (donde un programador escribe instrucciones tipo if/else para cada escenario posible), un sistema de IA se ajusta a través del análisis de datos. En el desarrollo de aplicaciones, la IA permite pasar de **programar respuestas** a **entrenar modelos** para que reconozcan o generen soluciones a partir de entradas de datos no estructurados (texto, imágenes, voz, o código).

No es IA

Los programas que usan las reglas de negocio o árboles de decisión (condicionales, etc.) no son IA.

Si no hay redes neuronales no hay IA.

Un breve paseo por la historia

La IA no nació ayer. Conocer su historia nos ayuda a entender por qué está explotando justamente ahora.

- **1950 - Alan Turing y su Test:** Alan Turing plantea la pregunta: *"¿Pueden pensar las máquinas?"* y crea el Test de Turing para evaluar si el comportamiento de una máquina es indistinguible del de un humano.
- **1956 - La Conferencia de Dartmouth:** Nace oficialmente el término "Inteligencia Artificial". Los científicos de la época eran muy optimistas y creían que en 20 años las máquinas harían todo el trabajo humano. Se equivocaron.
- **Los "Inviernos de la IA" (70s y 80s):** Las expectativas eran tan altas que, al no cumplirse (por falta de potencia de cálculo y datos), los gobiernos y empresas retiraron la financiación. La investigación se congeló.



- **1997 - Deep Blue derrota a Kasparov:** IBM demuestra el poder de la computación bruta. Su superordenador vence al campeón mundial de ajedrez.
- **2012 - La Revolución del Deep Learning:** Gracias a la potencia de las tarjetas gráficas (GPUs) y la cantidad masiva de datos en internet (Big Data), las Redes Neuronales Profundas empiezan a superar a los humanos en reconocimiento de imágenes.
- **2022 en adelante - La Era de la IA Generativa:** OpenAI lanza ChatGPT. La IA ya no solo clasifica o predice, sino que **genera** contenido nuevo (código, texto, imágenes).

La IA ha vivido un cambio de paradigma radical: pasar de "intentar programar la lógica humana a mano" a "dejar que la máquina aprenda sola".

- **La Era de los Sistemas Expertos (Años 80)**

Antes del auge actual, la IA se basaba en **Sistemas Expertos**. Los programadores picaban miles de líneas de reglas lógicas complejas (IF-THEN) codificando el conocimiento de un experto humano (por ejemplo, un médico).

- **El problema:** Eran sistemas extremadamente rígidos. Si el paciente tenía un síntoma que no estaba exactamente en las reglas, el sistema fallaba. No podían adaptarse ni aprender de casos nuevos.
- **El punto de inflexión: El Big Data y la Ley de Moore**

¿Por qué la IA está en su máximo esplendor ahora y no en los años 70? Por tres factores que coinciden en el tiempo:

1. **Datos masivos (Big Data):** Internet, las redes sociales y los smartphones generan billones de datos diarios que sirven de "alimento" para entrenar a las IA.
2. **Potencia de cálculo (Hardware):** Las GPUs (tarjetas gráficas desarrolladas originalmente para videojuegos) resultaron ser perfectas para realizar los miles de millones de cálculos matemáticos simultáneos que requieren las redes neuronales.
3. **Algoritmos optimizados:** Modelos matemáticos que existían desde los años 80 por fin pudieron ejecutarse gracias al hardware moderno.

Tipos de inteligencia artificial

Para no perdernos en la jerga técnica, clasificamos la IA según su alcance y según su enfoque tecnológico:

A. Según su alcance o capacidad

1. **IA Débil o Estrecha (ANI - Artificial Narrow Intelligence):** Es la única que existe hoy en día. Son sistemas entrenados para hacer **una sola tarea excepcionalmente bien**.
 - *Ejemplos:* El recomendador de Netflix, el reconocimiento facial de tu móvil, un bot que solo genera código Java.

2. **IA Fuerte o General (AGI - Artificial General Intelligence):** Una IA que puede comprender, aprender y aplicar conocimientos en cualquier tarea intelectual, igual o mejor que un ser humano. **Es teórica y aún no existe.**

B. Según su enfoque (Los pilares actuales que se explican más adelante)

- **Machine Learning (Aprendizaje Automático):** Algoritmos que mejoran automáticamente con la experiencia.
- **Deep Learning (Aprendizaje Profundo):** Una subcategoría del Machine Learning basada en **Redes Neuronales Artificiales** con muchas capas, imitando vagamente el cerebro humano. Es la tecnología detrás de la conducción autónoma y los traductores modernos.
- **IA Generativa (GenAI):** Modelos entrenados con volúmenes gigantescos de datos (LLMs o Grandes Modelos de Lenguaje) capaces de crear contenido original a partir de una instrucción o *prompt*.

Casos prácticos y ejemplos reales en el desarrollo de software

Como futuro desarrollador multiplataforma, la IA transformará tu día a día en tres áreas clave:

Desarrollo e Ingeniería de Software (Tu día a día)

- **Copilotos de Código:** Herramientas como *GitHub Copilot* o *Cursor* actúan como un compañero de programación en pareja (*Pair Programming*). Le escribes un comentario en castellano y te genera la función en Java o Python.
- **Refactorización y Debugging:** Puedes pasarle un código Java con un error de concurrencia y pedirle: *"Optimiza este código y evita los NullPointerException"*.



Aplicaciones de Consumo (Casos de Éxito)

- **Spotify/TikTok:** Analizan tus patrones de interacción (segundos que pasas viendo un vídeo, canciones que saltas) mediante Machine Learning para retenerte en la app.
- **Bizum / Apps Bancarias:** Utilizan IA en tiempo real para detectar si una transferencia es un fraude potencial analizando tu geolocalización y comportamiento habitual.

Automatización de Procesos (RPA + IA)

- Sistemas capaces de leer PDFs de facturas escaneadas de clientes, extraer los datos automáticamente mediante visión artificial (OCR inteligente) e introducirlos en la base de datos de la empresa sin intervención humana.

2. Machine learning y Deep Learning (dentro de la IA)


El **Machine Learning** (o Aprendizaje Automático) es una rama de la Inteligencia Artificial que permite a las computadoras aprender y tomar decisiones a partir de datos, sin ser programadas explícitamente para cada tarea específica. Tiene como objetivo el reconocimiento de patrones.

En lugar de escribir reglas fijas en código (como si pasa X, haz Y), le entregas grandes volúmenes de datos a un algoritmo para que identifique patrones por sí mismo y mejore sus predicciones con el tiempo.


Ejemplos reales:

Netflix va aprendiendo a sugerirte películas y series. Por categorías, cuándo las ves, cuáles ves de golpe, cuáles abandonas...

Sistemas bancarios, para patrones de pago y detectar fraudes, por ejemplo, en pago a horas no comunes.



Programación tradicional versus Machine Learning




Pasos en el ciclo del Machine Learning (para esperar algo adecuado)



3. Redes neuronales

Una red neuronal es un conjunto de unidades (neuronas artificiales) conectadas entre sí para transmitirse señales. Una información de entrada atraviesa la red neuronal y se transforma en una salida.

Es una creación humana para crear un modelo lógico. Es una red de nodos.




Notas: Oculta es la caja negra. Cualquier red pequeña tiene miles y miles de nodos.

Deep learning

El **Deep Learning** (o Aprendizaje Profundo) es un subcampo del Machine Learning que utiliza **redes neuronales artificiales** con múltiples capas (3 o más) para procesar datos complejos y no estructurados, como imágenes, audio o texto.

Su estructura está inspirada libremente en la forma en que interactúan las neuronas en el cerebro humano. La palabra "profundo" hace referencia a la cantidad de capas ocultas (*hidden layers*) que conectan la entrada (*input*) con la salida (*output*), permitiendo extraer características cada vez más abstractas en cada nivel.



Diferencias con el Machine Learning tradicional

Característica	Machine Learning Tradicional	Deep Learning
Intervención humana	Requiere que un humano extraiga manualmente las características importantes de los datos. Procesamiento previo de los humanos.	Extrae las características automáticamente a través de sus capas. Automatiza la extracción de las características.
Tipo de datos	Funciona mejor con datos estructurados (tablas, hojas de cálculo, bases de datos) y etiquetados previamente para realizar predicciones.	Destaca con datos no estructurados (imágenes, video, audio, lenguaje natural).
Volumen de datos	Rinde bien con conjuntos de datos pequeños o medianos.	Necesita enormes volúmenes de datos para ser preciso.
Cómputo	Funciona en procesadores estándar (CPU).	Requiere alto poder de cómputo en paralelo (GPU o TPU).

Nota: Una GPU (Unidad de Procesamiento Gráfico) es un chip especializado en procesar gráficos y realizar muchas tareas a la vez (es el chip central de una tarjeta gráfica), mientras que una TPU (Unidad de Procesamiento Tensorial) es un chip creado por Google exclusivamente para acelerar la inteligencia artificial y el aprendizaje automático.

4. Modelos de aprendizaje

Los **modelos de aprendizaje** son los enfoques, algoritmos y paradigmas que se utilizan para entrenar a una máquina y permitirle identificar patrones, tomar decisiones o hacer predicciones a partir de datos.

Dependiendo de la naturaleza de los datos disponibles y del objetivo planteado, el aprendizaje automático se divide en cuatro paradigmas principales:

1. Aprendizaje Supervisado (*Supervised Learning*)

El modelo se entrena utilizando un conjunto de **datos etiquetados**, lo que significa que cada entrada ya viene acompañada de la respuesta correcta. Su objetivo es aprender una función que asocie una entrada con su correspondiente salida.

Hay intervención humana.

- **Cómo funciona:** La máquina recibe pares de entradas y salidas deseada (ej. [foto] -> gato), hace una predicción, mide el error comparándolo con la etiqueta real y ajusta sus parámetros internos.
- **Tipos principales:**
 - **Clasificación:** Asigna etiquetas discretas (ej. detectar si un correo es *spam* o *no spam*, diagnóstico de enfermedades).
 - **Regresión:** Predice valores numéricos continuos (ej. precio de una casa, predicción de temperatura).
- **Algoritmos populares:** Regresión Lineal/Logística, Árboles de Decisión, Random Forest, Máquinas de Vectores de Soporte (SVM), Redes Neuronales.

Ejemplo real clasificación: Filtro anti-Spam de Gmail

El problema: Determinar si un correo entrante es correo deseado o *spam*.

Los datos: Millones de correos etiquetados explícitamente **por usuarios** y expertos como "Spam" o "No Spam".

Cómo actúa: El algoritmo analiza las palabras clave, el remitente y los enlaces del mensaje. Al estar entrenado con etiquetas, calcula la probabilidad de que sea basura y lo envía a la carpeta correspondiente.

Ejemplo real regresión

Predecir el precio de venta de un piso en Sevilla. Le pasamos al algoritmo datos etiquetados (metros cuadrados, barrio, número de habitaciones y el precio real al que se vendió). El modelo aprende la relación matemática y, cuando le des un piso nuevo, te dirá su valor estimado en euros.


2. Aprendizaje No Supervisado (*Unsupervised Learning*)

El modelo trabaja con **datos sin etiquetar**. No hay respuestas correctas previa ni una guía externa; el algoritmo explora los datos para descubrir estructuras, agrupaciones o patrones ocultos por sí solo.

- **Cómo funciona:** Analiza la similitud y las relaciones entre los puntos de datos para organizarlos.
- **Tipos principales:**
 - **Agrupamiento (*Clustering*):** Divide los datos en grupos con características similares (ej. segmentación de clientes según comportamiento de compra).
 - **Reducción de dimensionalidad:** Simplifica conjuntos de datos complejos reduciendo el número de variables sin perder información clave (ej. PCA).
 - **Asociación:** Descubre reglas que describen grandes cantidades de datos (ej. "los clientes que compren pan también suelen comprar mantequilla").
- **Algoritmos populares:** K-Means, DBSCAN, PCA (Análisis de Componentes Principales), Isolation Forest.

Ejemplos reales: Recomendaciones de Netflix o Spotify

- **El problema:** Descubrir grupos de usuarios con gustos similares sin que nadie haya etiquetado previamente sus perfiles.
- **Los datos:** Historial de reproducción, horas de conexión y canciones/películas guardadas (sin etiquetas de "tipo de usuario").
- **Cómo actúa:** Utiliza algoritmos de agrupamiento (*clustering*) para identificar patrones comunes. Si detecta que tú y otros mil usuarios ven las mismas series de ciencia ficción a la misma hora, te recomendará lo que ellos vieron y tú aún no.



3. Aprendizaje Semi-Supervisado (*Semi-Supervised Learning*)

Combina los dos enfoques anteriores. Utiliza una **pequeña cantidad de datos etiquetados junto con un gran volumen de datos sin etiquetar**.

- **Por qué se usa:** Etiquetar datos suele ser costoso, lento o requiere expertos humanos (por ejemplo, radiografías médicas). Usar una mezcla permite entrenar modelos muy precisos a una fracción del costo.
- **Caso de uso:** Clasificación de imágenes médicas o análisis de grandes volúmenes de texto.

Ejemplo real: Diagnóstico Médico por Imagen

- **El problema:** Entrenar una IA para detectar tumores en radiografías cuando clasificar imágenes a mano es extremadamente costoso (requiere horas de un médico especialista).
- **Los datos:** Un grupo pequeño de 500 radiografías etiquetadas minuciosamente por radiólogos, combinado con un banco masivo de 100.000 radiografías sin etiquetar.
- **Cómo actúa:** El modelo aprende los conceptos básicos con las 500 imágenes etiquetadas y luego aplica ese conocimiento para estructurar y entender las 100.000 restantes, logrando una alta precisión a una fracción del costo.

4. Aprendizaje por Refuerzo (*Reinforcement Learning*)


Un **agente** aprende a tomar decisiones y a ser más preciso interactuando de forma dinámica con un **entorno**. No se le enseñan las acciones correctas, sino que aprende mediante un sistema de **recompensas y castigos** (ensayo y error). Como los seres humanos o algunas mascotas.

- **Cómo funciona:** El agente realiza una acción, observa el cambio en el entorno y recibe un incentivo positivo o negativo. Su objetivo es maximizar la recompensa acumulada a largo plazo.
- **Casos de uso:** Robótica, coches autónomos, optimización de redes de logística y sistemas que juegan al ajedrez o al Go (ej. AlphaGo).
- **Algoritmos populares:** Q-Learning, Deep Q-Networks (DQN), PPO.

Ejemplos reales: AlphaGo y la Conducción Autónoma de Tesla

- **El problema:** Tomar decisiones óptimas en entornos dinámicos y cambiantes.
- **Los datos:** Interacciones directas con el entorno mediante simulaciones o sensores en tiempo real.
- **Cómo actúa:**
 - **AlphaGo (DeepMind):** Aprendió a jugar al Go jugando millones de partidas contra sí mismo. Ganaba puntos (recompensa) al hacer jugadas ganadoras y los perdía al cometer errores.

- **Coches autónomos:** En un simulador, el vehículo recibe una "recompensa" por mantenerse en el carril y avanzar de forma fluida, y un "castigo" virtual si se acerca demasiado a un obstáculo o frena de manera brusca.



Comparativa

Paradigma	Datos de Entrada	Objetivo Principal	Ejemplo Típico
Supervisado	Etiquetados	Predecir un resultado o categoría	Detección de transacciones fraudulentas
No Supervisado	Sin etiquetar	Encontrar patrones o agrupar datos	Segmentación de audiencias
Semi-Supervisado	Mezcla (pocos etiquetados, muchos sin etiquetar)	Mejorar precisión con menor costo de etiquetado	Clasificación de texto a gran escala
Por Refuerzo	Interacción con entorno (Recompensas/Castigos)	Aprender una secuencia de decisiones óptimas	Navegación de drones autónomos

5. Dataset

Un **dataset** (o set=conjunto de data=datos) es una colección organizada de datos e información relacionada entre sí, estructurada de tal manera que un ordenador pueda procesarla, analizarla o usarla para entrenar modelos de Inteligencia Artificial. También se puede usar en la validación o en las pruebas.


Un dataset puede ser un archivo CSV con 10.000 o 1 millón de filas. Cuanto mayor es el set de datos mejor será el modelo resultante pero también más costoso y largo será el entrenamiento. Quizá en determinados procesos no interesa ir a Big Data porque no es necesario.



Piensa en un dataset como el "alimento" que consumen los algoritmos de Machine Learning y Deep Learning: cuanto mejor sea la calidad y cantidad de este alimento, más preciso y confiable será el modelo.

Huggingface continúe una sección completa de Datasets.

Más adelante cuando veamos IAs generativas de imágenes veremos datasets con millones de pares de imágenes y texto.



Estructura básica de un dataset

En su forma más común (datos estructurados en tablas o CSV), un dataset se organiza en:

- **Filas (Muestras / Registros / Instancias):** Cada elemento individual del conjunto. Por ejemplo, la información de un paciente específico, un cliente o una transacción bancaria.
- **Columnas (Características / Features):** Las propiedades o variables que describen a cada muestra. Por ejemplo: Edad, Precio, Color, Ubicación.
- **Etiqueta (Target / Label):** En el aprendizaje supervisado, es la columna que contiene la respuesta correcta que el modelo debe aprender a predecir (ej. ¿Es Fraude? Si/No).

Tipos de datos en un dataset

Tipo	Formato	Ejemplos
Estructurados	Tablas, hojas de cálculo (CSV, SQL).	Historiales de ventas, datos meteorológicos, registros de clientes.
No estructurados	Archivos sin una tabla fija.	Colecciones de imágenes, archivos de audio, videos, publicaciones en redes sociales.
Semiestructurados	Tienen marcadores o etiquetas pero no una tabla fija.	Archivos JSON, XML, código HTML.

División de un dataset en machine Learning

Cuando se entrena un modelo, el dataset suele dividirse (hacer split) en tres partes clave:

1. **Conjunto o split de Entrenamiento (*Training set*, ~70-80%):** Los datos con los que el algoritmo aprende e identifica patrones.
2. **Conjunto o split de Validación (*Validation set*, ~10-15%):** Se usa para ajustar los parámetros del modelo mientras aprende y evitar que simplemente "memorice" (sobreajuste o *overfitting*).
3. **Conjunto o split de Prueba o test (*Test set*, ~10-15%):** Datos completamente nuevos para el modelo que sirven para evaluar su rendimiento real en el mundo real.

Datasets famosos en la industria

- **MNIST:** Colección de 70,000 imágenes de dígitos escritos a mano (0 al 9), considerado el "Hola Mundo" del reconocimiento de imágenes.
- **ImageNet:** Más de 14 millones de imágenes etiquetadas en miles de categorías, fundamental para el avance del Deep Learning en visión por computadora.
- **Kaggle:** La plataforma más popular donde la comunidad comparte miles de datasets abiertos sobre finanzas, deportes, salud y más.

Ejemplo práctico

Imagina que tenemos un dataset de 10 mil imágenes y queremos categorizar imágenes, es decir, si aparece una manzana me va a decir, en la imagen hay una manzana.

- Entrenamiento: 70%, es decir, 7 mil imágenes para entrenar el modelo.

- Validación: 15%, es decir, 1500 para ajustar hiperparámetros y monitorear el proceso de entrenamiento.

Estas son imágenes que NO están en el entrenamiento y vemos cómo reacciona el modelo cuando las paso.

- Pruebas: 15%, otras 1500 imágenes para evaluar el proceso final del modelo. Estas tampoco las ha visto el modelo en el proceso de aprendizaje.

Esta división ayuda a que el modelo no solo aprenda a “memorizar” los datos de entrenamiento sino que también sea capaz de generalizar y funcionar bien con nuevos datos.

6. Data Science

El **Data Science** (o Ciencia de Datos) es un campo interdisciplinario que combina matemáticas, estadística, programación e inteligencia artificial con el conocimiento de un negocio o dominio específico, para extraer ideas valiosas (*insights*) a partir de datos estructurados y no estructurados, es decir, recopila y analiza datos

con la idea de predecir comportamientos y tomar decisiones que nos llevarán a crear o mejorar productos y servicios.

Mientras que el **Machine Learning** se enfoca en crear algoritmos que aprenden por sí solos, el **Data Science** abarca todo el ciclo de vida de los datos: desde recolectarlos y limpiarlos, hasta analizarlos, interpretarlos y comunicarlos para tomar decisiones estratégicas.

El ciclo de vida del Data Science

1. **Definición del problema:** Entender la pregunta de negocio (ej. "*¿Por qué están cancelando su suscripción los clientes?*").
2. **Obtención de datos:** Extraer información de bases de datos, APIs, archivos o páginas web (*web scraping*).
3. **Limpieza y preparación (Data Wrangling):** Eliminar duplicados, corregir errores y estructurar el dataset.
4. **Análisis Exploratorio (EDA):** Usar estadística y gráficos para encontrar patrones iniciales y tendencias.
5. **Modelado (Machine / Deep Learning):** Construir algoritmos predictivos o clasificadores si el problema lo requiere.
6. **Interpretación y Comunicación:** Presentar las conclusiones mediante cuadros de mando (*dashboards*) o informes comprensibles para los líderes de la empresa.

Relación entre Data Science, IA y Machine Learning

- **Inteligencia Artificial:** El concepto amplio de crear máquinas inteligentes.
- **Machine Learning:** Las herramientas informáticas y modelos predictivos dentro de la IA.
- **Data Science:** La disciplina completa que aplica Machine Learning, estadística y análisis de datos para resolver problemas reales.



Roles clave en el mundo de los datos

Rol	Enfoque Principal	Herramientas Típicas
Data Analyst	Analiza datos pasados y presentes para responder preguntas operativas.	SQL, Excel, Power BI, Tableau
Data Scientist	Crea modelos predictivos, estadísticas avanzadas y algoritmos de ML.	Python, R, SQL, Scikit-learn
Data Engineer	Diseña e implementa la infraestructura necesaria para mover y almacenar grandes volúmenes de datos.	Spark, Hadoop, SQL, AWS, Airflow

7. Transformers (“la T del ChatGPT”)

Un **Transformer** es una arquitectura de red neuronal profunda, introducida por Google en 2017 en el famoso artículo *"Attention Is All You Need"*, que revolucionó el Procesamiento del Lenguaje Natural (NLP) y constituye la base de todos los modelos de lenguaje modernos (como GPT-4, Claude o Gemini).

A diferencia de las redes neuronales anteriores (como las RNN o LSTM), que procesaban el texto **palabra por palabra de forma secuencial**, los Transformers procesan **todas las palabras al mismo tiempo (en paralelo)**.

Están basados en dos conceptos clave: atención y contexto. Los transformes han superado a las redes Neuronales convencionales en la generación de texto, por ejemplo, para generar texto.



Ejemplo

Si alguien te dice “En un lugar de la Mancha...” y has leído el Quijote puedes “predecir” qué viene después “...de cuyo nombre no quiero acordarme”.

Digamos que si los transformers se han leído “internet entera” son capaces de predecir qué va después de un texto dado. Predicen la siguiente palabra más probable.

Analizan las relaciones entre las palabras que hay en una oración e intenta detectar cómo se influyen estas palabras entre sí o cómo dependen unas de otras. esto es lo que hace ChatGPT.

Esto lo descubrió Google, pero fue OpenAI (fundada por Elon Musk y Sam Altman en 2015, Elon Musk el visionario se fue de ella) la que lo desarrolló.

Los usan muchas empresas y los algoritmos están disponibles para todo el mundo: Claude, Perplexity, Gemini...

ChatGPT (de OpenAI): Versátil, enfocado en conversaciones e integración de tareas generales. Se ha ido enriqueciendo, sobre todo en matemáticas (era muy malo). (EEUU, 2022)

Claude (de Anthropic): Pone el foco en comprensión y generación de texto con alta precisión y es bueno para el análisis detallado y de código, por lo que es muy usado por desarrolladores para autocompletar. (EEUU, 2021)

Perplexity (de PerplexityIA): Respuestas basadas en datos y generación de estructuras y explicaciones con fuentes, verifica mucho la realidad y las fuentes, contextualiza. (EEUU, 2022).

Gemini (De Google): Tiene muchas variantes, pero permite contextos muy grandes. Está orientado a la creación de contenido y análisis de documentos muy grandes con capacidades orientadas a empresa. (EEUU, Google-división DeepMind, 2023).

Los 3 pilares del funcionamiento de un Transformer

1. Mecanismo de Atención (*Self-Attention*):

- Es el núcleo del Transformer. Permite que el modelo evalúe la relación y relevancia de cada palabra con respecto a todas las demás dentro de una misma frase.
- **Ejemplo:** En "*El banco de la plaza estaba roto*", el mecanismo de atención entiende que la palabra "*banco*" se refiere a un asiento y no a una entidad financiera gracias al contexto de "*plaza*".

2. Procesamiento en Paralelo:

- Al no requerir un procesamiento secuencial paso a paso, aprovecha al máximo la capacidad de cómputo de las GPU. Esto permite entrenar modelos con miles de millones de parámetros sobre enormes volúmenes de texto en tiempos viables.

3. Codificación Posicional (*Positional Encoding*):

- Como el modelo analiza todas las palabras a la vez, no sabe en qué orden llegaron. Para resolver esto, añade una "marca de posición" matemática a cada palabra para recordar su orden original en la frase.

Arquitectura: Codificador y Decodificador

El Transformer original se divide en dos bloques principales:

- **Codificador (*Encoder*):** Recibe la secuencia de entrada, la analiza y la convierte en una representación matemática rica en contexto.
- **Decodificador (*Decoder*):** Toma esa representación y genera la secuencia de salida palabra por palabra (por ejemplo, la traducción a otro idioma o la respuesta a una pregunta).
- **Codificador + Decodificador:** mezcla de ambos.

Tipos de modelos según su arquitectura

Tipo	Componentes	Ejemplo Famoso	Uso Principal
Solo Codificador	Encoder	BERT	Clasificación de texto, búsqueda y análisis de sentimiento.
Solo Decodificador	Decoder	GPT, LLaMA	Generación de texto, asistencia en código y conversación.
Codificador Decodificador	+ Encoder + Decoder	T5, Whisper	Traducción automática y transcripción de audio.

